



Qiskit Finance Tutorial

Yuma Nakamura
Qiskit Advocate



1. Option Pricingとは？
2. qGANによる確率分布の再現
3. Payoff関数のエンコード
4. まとめ

Option Pricingとは?

Optionとは満期に株を権利行使価格で買う/売る権利(義務ではない)

権利行使価格: K


満期のスポット価格: S_T

このときPayoff関数は

$$\max\{S_T - K, 0\}$$

つまり買い(Call Option)では

- スポット価格が権利行使価格より高い場合、利益が発生
- スポット価格が権利行使価格より低い場合、損益なし(買う義務はないので)



この権利をいくらで取引するかを決める問題がOption Pricing

Option Pricingとは? --例題--

Question:

\$10で株AのCall Option(満期 2021年10月、権利行使価格\$100)を買ったとする

シナリオ1

2021年10月の株Aの価格が\$130になった

→利益/損失は?

シナリオ2

2021年10月の株Aの価格が\$80になった

→利益/損失は?

*ここでは利息は考えていない。実際は今買った場合の利息分を利益から差引く。
利息分の計算は古典計算で十分なのでチュートリアル・原著論文では割愛されている

Option Pricingとは? --例題--

Question:

\$10で株AのCall Option(満期 2021年10月、権利行使価格\$100)を買ったとする

シナリオ1

2021年10月の株Aの価格が\$130になった

→利益/損失は?

$$\max(\$130 - \$100, 0) - \$10 = \$20$$

\$20の利益

シナリオ2

2021年10月の株Aの価格が\$80になった

→利益/損失は?

$$\max(\$80 - \$100, 0) - \$10 = -\$10$$

\$10の損失



*ここでは利息は考えていない。実際は今買った場合の利息分を利益から差引く。
利息分の計算は古典計算で十分なのでチュートリアル・原著論文では割愛されている

Option Pricingとは?

満期のスポット価格の確率分布が与えられたとき、最適なOption価格は?

スポット価格の分布は対数正規分布で近似できる
(Black-Scholes model)

$$f(x) = \frac{1}{\sqrt{2\pi\sigma x}} \exp\left(-\frac{(\log x - \mu)^2}{2\sigma^2}\right)$$



→Payoff関数(右図)の期待値を価格の確率分布(左図)をもとに積分計算

Option Pricing計算フロー

(1) 確率分布 p_i を量子状態にエンコード



$$|\psi_1\rangle = \sum_{i=0}^{2^n-1} \sqrt{p_i} |i\rangle_n$$

(2) Payoff関数 f_i を量子状態にエンコード

$$|\psi_2\rangle = \sum_{i=0}^{2^n-1} \sqrt{1-f_i} \sqrt{p_i} |i\rangle_n |0\rangle + \sum_{i=0}^{2^n-1} \sqrt{f_i} \sqrt{p_i} |i\rangle_n |1\rangle$$

(3) Payoffの期待値として振幅 $\sum_{i=0}^{2^n-1} (\sqrt{f_i} \sqrt{p_i})^2$ を計算

$$|\psi_2\rangle = \sum_{i=0}^{2^n-1} \sqrt{1-f_i} \sqrt{p_i} |i\rangle_n |0\rangle + \sum_{i=0}^{2^n-1} \sqrt{f_i} \sqrt{p_i} |i\rangle_n |1\rangle$$



Option Pricing計算フロー

(1) 確率分布 p_i を量子状態にエンコード

$$|\psi_1\rangle = \sum_{i=0}^{2^n-1} \sqrt{p_i} |i\rangle_n$$

本日のメイン
Quantum GAN
(Machine Learning)

(2) Payoff関数 f_i を量子状態にエンコード


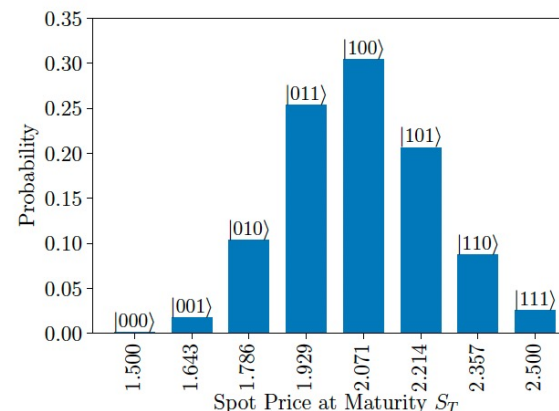
$$|\psi_2\rangle = \sum_{i=0}^{2^n-1} \sqrt{1-f_i} \sqrt{p_i} |i\rangle_n |0\rangle + \sum_{i=0}^{2^n-1} \sqrt{f_i} \sqrt{p_i} |i\rangle_n |1\rangle$$

Controlled-Ry

(3) Payoffの期待値として振幅 $\sum_{i=0}^{2^n-1} (\sqrt{f_i} \sqrt{p_i})^2$ を計算

$$|\psi_2\rangle = \sum_{i=0}^{2^n-1} \sqrt{1-f_i} \sqrt{p_i} |i\rangle_n |0\rangle + \sum_{i=0}^{2^n-1} \sqrt{f_i} \sqrt{p_i} |i\rangle_n |1\rangle$$

Amplitude Estimation
(詳しくは田中さんが後日発表)



Quantum GAN 価格確率分布の量子状態作成

量子敵対的生成ネットワークなるものを使って確率分布を作成する


npj | Quantum Information

www.nature.com/npjqi

ARTICLE OPEN

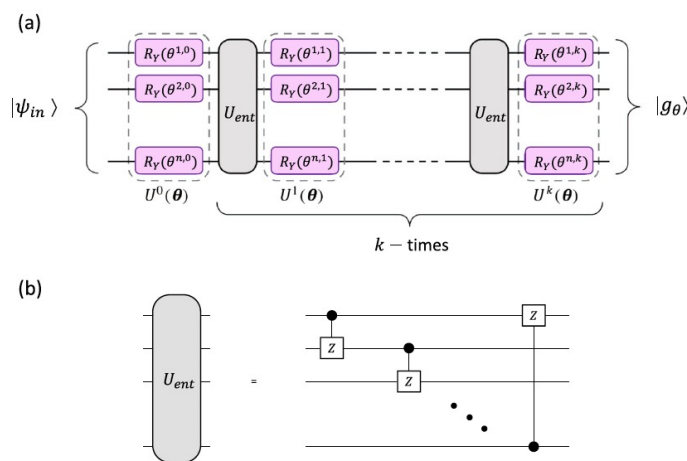
Quantum Generative Adversarial Networks for learning and loading random distributions

Christa Zoufal^{1,2*}, Aurélien Lucchi² and Stefan Woerner¹



ref: C. Zoufal et al., 2019

変分量子回路(Variational Quantum Circuit; VQC)



所望の確率分布を実現するようにパラメータ θ_{ij} を決定

Quantum GAN 価格確率分布の量子状態作成

量子部分のGeneratorと古典部分のDiscriminatorを競合させながら学習をする

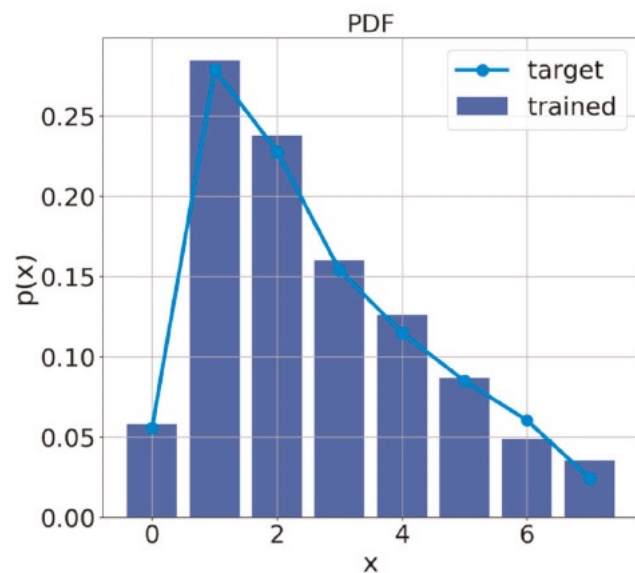
npj | Quantum Information

www.nature.com/npjqi

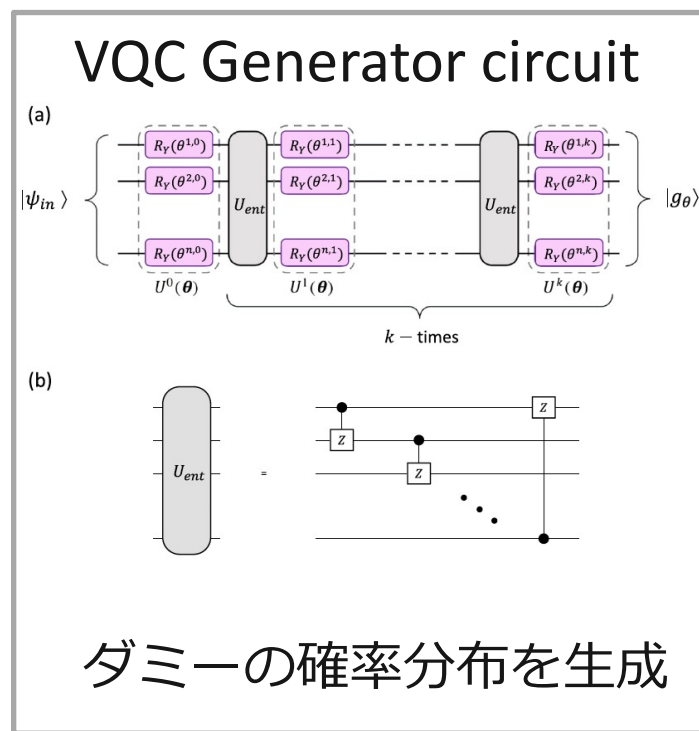
ARTICLE OPEN

Quantum Generative Adversarial Networks for learning and loading random distributions

Christa Zoufal^{1,2*}, Aurélien Lucchi² and Stefan Woerner¹




ref: C. Zoufal et al., 2019




なぜqGANを使うか？

価格の確率分布は制御 R_Y ゲートを使うことで系統的にエンコードできるが $O(2^n)$ のゲートが必要
qGANを使うと $O(\text{poly}(n))$ のゲートで実装可能


系統的アプローチ 1/3



確率分布を2分割に集約して再現



$$R_Y(\theta) = \exp(-i\frac{\theta}{2}Y) = \begin{pmatrix} \cos \frac{\theta}{2} & -\sin \frac{\theta}{2} \\ \sin \frac{\theta}{2} & \cos \frac{\theta}{2} \end{pmatrix}$$



$$\theta_0 = 2 \arccos(\sqrt{p_0})$$

$$|\psi_1\rangle = R_Y(\theta_0)|0\rangle = \cos\left(\frac{\theta_0}{2}\right)|0\rangle + \sin\left(\frac{\theta_0}{2}\right)|1\rangle$$


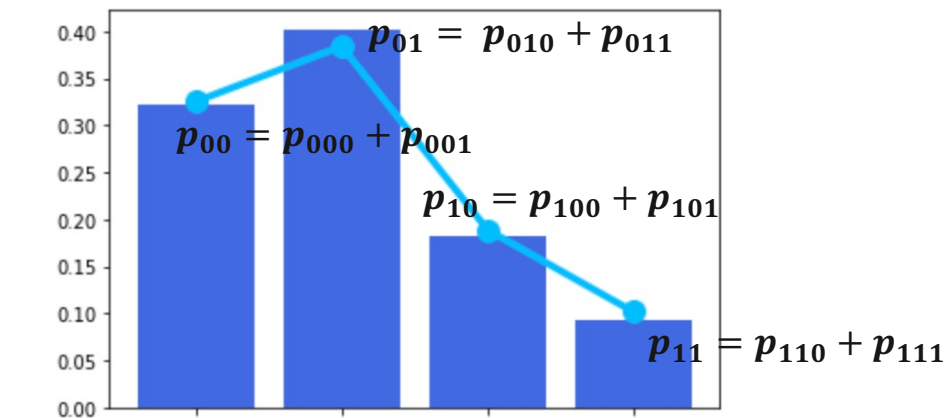
なぜqGANを使うか？

価格の確率分布は制御Ryゲートを使うことで系統的にエンコードできるが $O(2^n)$ のゲートが必要
qGANを使うと $O(\text{poly}(n))$ のゲートで実装可能

系統的アプローチ 2/3



確率分布を4分割に集約し再現



7 u3 gates
4 cx gates

$$\theta_1 = 2 \arccos(\sqrt{p_{00}/p_0})$$

$$\theta_2 = 2 \arccos(\sqrt{p_{10}/p_1})$$


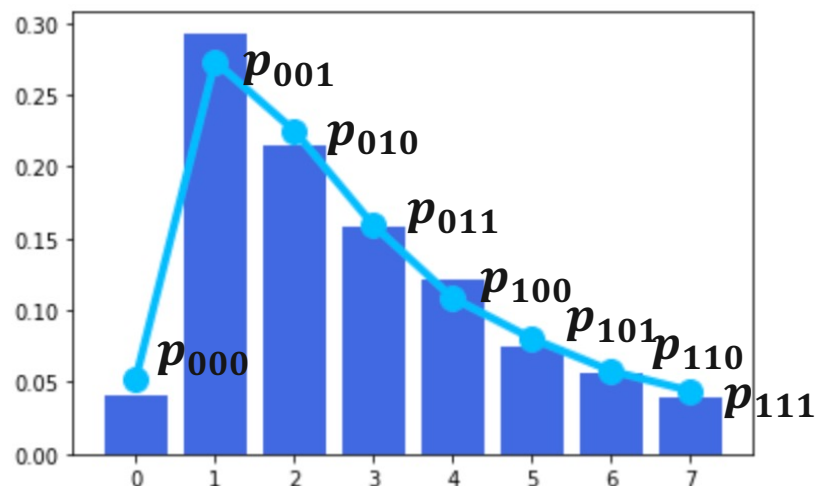
$$|\psi_1\rangle = \cos\left(\frac{\theta_0}{2}\right)|0\rangle\left(\cos\left(\frac{\theta_1}{2}\right)|0\rangle + \sin\left(\frac{\theta_1}{2}\right)|1\rangle\right) + \sin\left(\frac{\theta_0}{2}\right)|1\rangle\left(\cos\left(\frac{\theta_2}{2}\right)|0\rangle + \sin\left(\frac{\theta_2}{2}\right)|1\rangle\right)$$

なぜqGANを使うか？

価格の確率分布は制御Ryゲートを使うことで系統的にエンコードできるが $O(2^n)$ のゲートが必要
qGANを使うと $O(\text{poly}(n))$ のゲートで実装可能

系統的アプローチ 3/3

確率分布を8分割に集約し再現




$$\begin{aligned} |\psi_1\rangle = & \cos\left(\frac{\theta_0}{2}\right) \cos\left(\frac{\theta_1}{2}\right) |00\rangle \left(\cos\left(\frac{\theta_3}{2}\right) |0\rangle + \sin\left(\frac{\theta_3}{2}\right) |1\rangle\right) + \cos\left(\frac{\theta_0}{2}\right) \sin\left(\frac{\theta_1}{2}\right) |01\rangle \left(\cos\left(\frac{\theta_4}{2}\right) |0\rangle + \sin\left(\frac{\theta_4}{2}\right) |1\rangle\right) \\ & + \sin\left(\frac{\theta_0}{2}\right) \cos\left(\frac{\theta_2}{2}\right) |10\rangle \left(\cos\left(\frac{\theta_5}{2}\right) |0\rangle + \sin\left(\frac{\theta_5}{2}\right) |1\rangle\right) + \sin\left(\frac{\theta_0}{2}\right) \sin\left(\frac{\theta_2}{2}\right) |11\rangle \left(\cos\left(\frac{\theta_6}{2}\right) |0\rangle + \sin\left(\frac{\theta_6}{2}\right) |1\rangle\right) \end{aligned}$$

ref: https://qiskit.org/documentation/locale/ja_JP/tutorials/finance/10_qgan_option_pricing.html

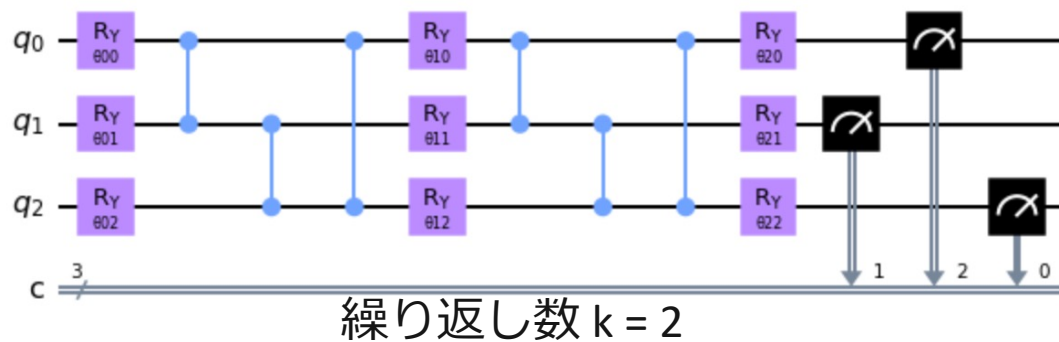
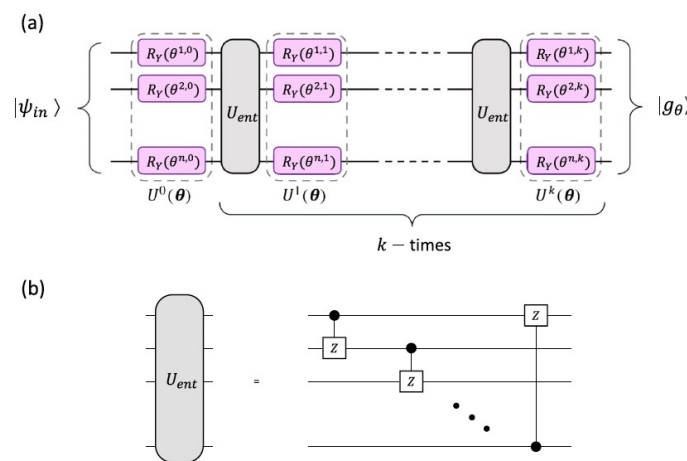
なぜqGANを使うか？

価格の確率分布は制御Ryゲートを使うことで系統的にエンコードできるが $O(2^n)$ のゲートが必要
qGANを使うと $O(\text{poly}(n))$ のゲートで実装可能

qGANを使った場合




VQC Generator circuit



適切なパラメータ θ_{ij} で確率分布を実現可能
→変分法により θ_{ij} を決定

$n(k+1)$ Ry gates
 nk cz gates

qGanのアーキテクチャー



(1) Q-Generatorで確率分布を出力(shots数=batch size)

(2) 本来の確率分布とQ-Generatorが作る確率分布を区別できるようにDiscriminatorを訓練

最適化関数:
$$L_D(D_\phi, G_\theta) = \frac{1}{m} \sum_{l=1}^m [\log D_\phi(\mathbf{x}^l) + \log(1 - D_\phi(G_\theta(\mathbf{z}^l)))]$$

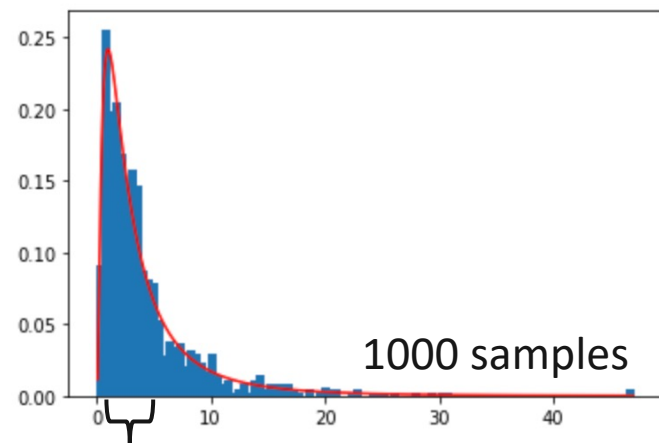
(3) Discriminatorがダミーの確率分布を正しいと判定するようにQ-Generatorを訓練

最適化関数:
$$L_G(\phi, \theta) = -\frac{1}{m} \sum_{l=1}^m [\log(D_\phi(G_\theta(\mathbf{z}^l)))]$$

D_ϕ : Discriminatorの分類結果
 x : 本来の確率分布からの
サンプリング度数分布
 $G_\theta(z)$: Generatorによる度数分布
 m : Batchサイズ

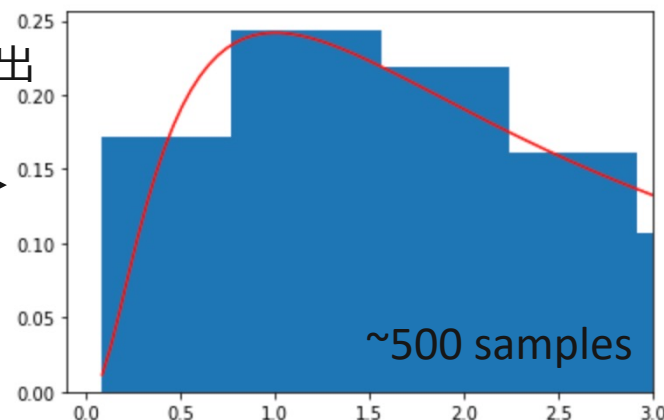
qGanのアーキテクチャー –Discriminatorが使う正解データ

目的の確率分布からサンプリング




対象区間を[0,3]とする

対象区間の抽出
(truncate)



[00, 01, 10, 11]
で離散化



サンプリング例: [1, 2, 1, 0, 0, 1, 2, 3,]

~500 samples

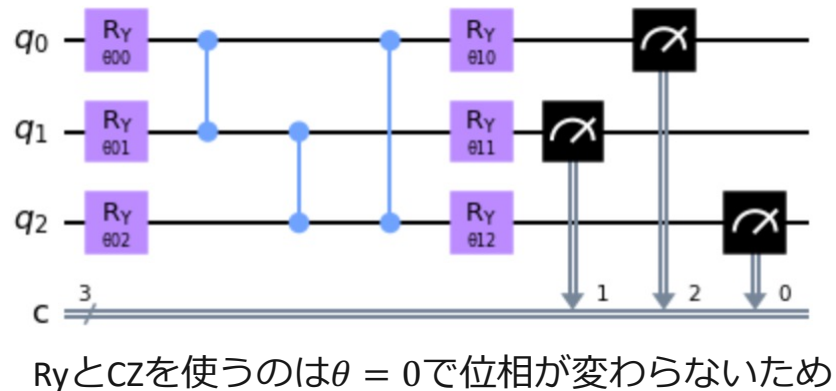
Batch*毎の度数分布を予測の特徴量としてDiscriminatorで学習

Prob	00	01	10	11
batch_1	0.13	0.45	0.31	0.11
batch_2	0.15	0.45	0.32	0.08
batch_3	0.00	0.43	0.42	0.15
batch_4	0.12	0.40	0.35	0.13
batch_5	0.05	0.37	0.42	0.15
batch_6	0.03	0.41	0.38	0.17

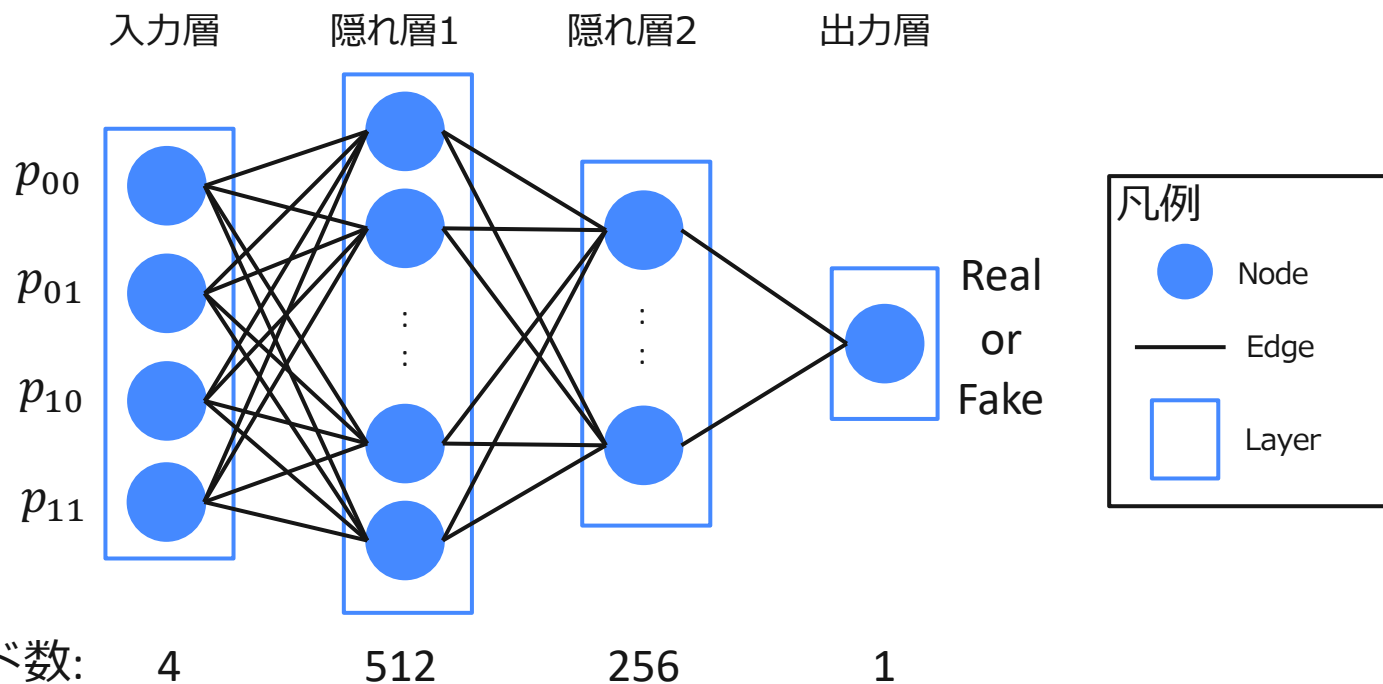
*batch size =100

qGanのアーキテクチャー

Q-Generator



Discriminator



- (1) Q-Generatorで確率分布を出力(shots数=batch size)
- (2) 本来の確率分布とQ-Generatorが作る確率分布を区別できるようにDiscriminatorを訓練

最適化関数:
$$L_D(D_\phi, G_\theta) = \frac{1}{m} \sum_{l=1}^m [\log D_\phi(\mathbf{x}^l) + \log(1 - D_\phi(G_\theta(\mathbf{z}^l)))]$$

- (3) Discriminatorがダミーの確率分布を正しいと判定するようにQ-Generatorを訓練

最適化関数:
$$L_G(\phi, \theta) = -\frac{1}{m} \sum_{l=1}^m [\log(D_\phi(G_\theta(\mathbf{z}^l)))]$$

D_ϕ : Discriminatorの分類結果
 x : 本来の確率分布からの
サンプリング度数分布
 $G_\theta(z)$: Generatorによる度数分布
 m : Batchサイズ

再現度合いの指標

相対エントロピーによって本来の確率分布と生成された確率分布の差異を定量化

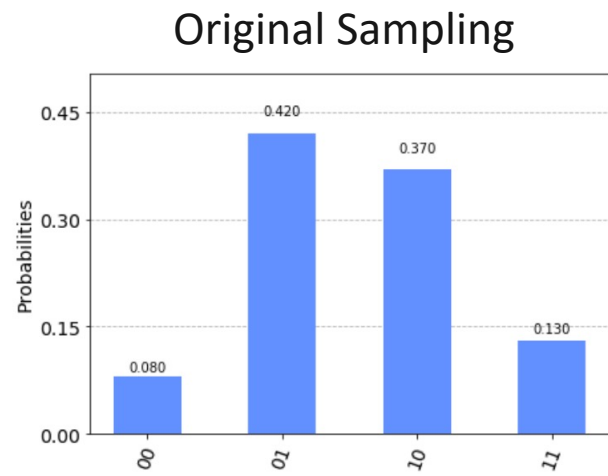
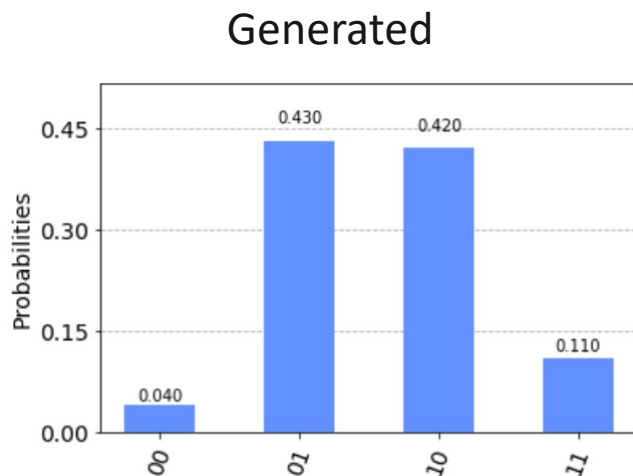
相対エントロピー

$$D_{\text{KL}}(P\|Q) = \sum_j p_j \log \frac{p_j}{q_j}.$$

p_j : 生成された確率分布

q_j : 本来の確率分布

Probability	00	01	10	11
Generated	0.04	0.43	0.42	0.10
Original	0.08	0.42	0.37	0.13



$$D_{KL} = 0.04 \log \frac{0.04}{0.08} + 0.43 \log \frac{0.43}{0.42} + 0.42 \log \frac{0.42}{0.37} + 0.10 \log \frac{0.10}{0.13} = 0.02$$

小さい値になるほど類似

変分量子回路Tips

- ・ 繰り返し数 k を増やすと性能向上する傾向がある
- ・ 初期化する分布が結果に大きく影響(正規分布が◎)

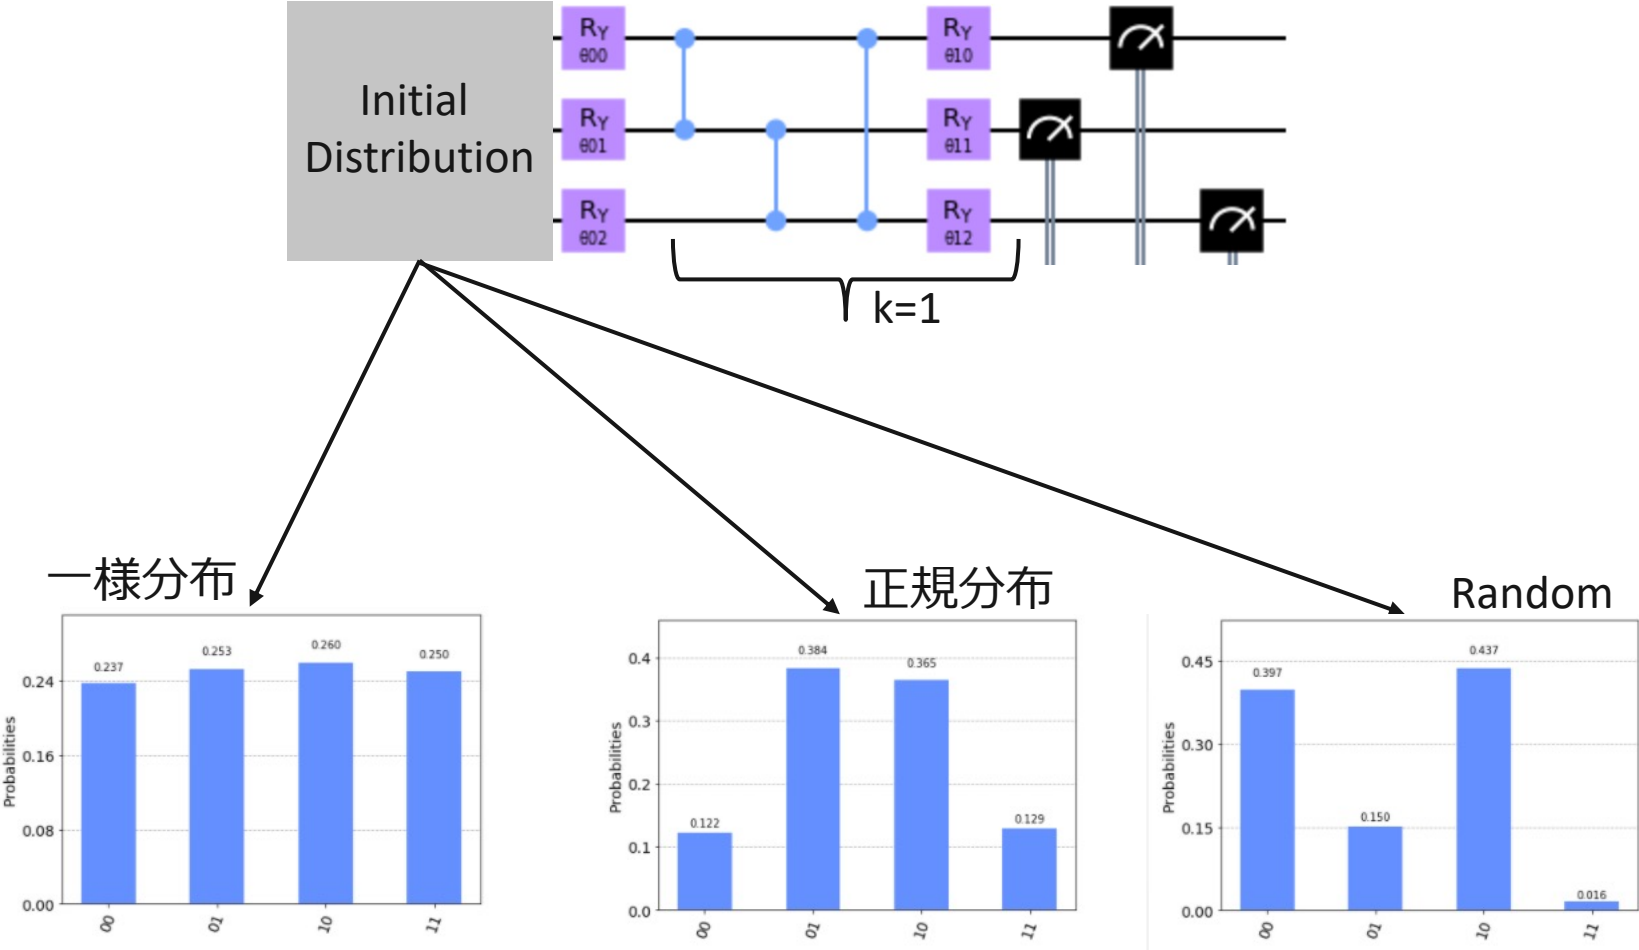


Table 1. Benchmarking the qGAN training.

Data	Initialization	k	μ_{KS}	σ_{KS}	$n_{\leq b}$	μ_{RE}	σ_{RE}
Log-normal	Uniform	1	0.0522	0.0214	9	0.0454	0.0856
		2	0.0699	0.0204	7	0.0739	0.0510
		3	0.0576	0.0206	9	0.0309	0.0206
	Normal	1	0.1301	0.1016	5	0.1379	0.1449
		2	0.1380	0.0347	1	0.1283	0.0716
		3	0.0810	0.0491	7	0.0435	0.0560
	Random	1	0.0821	0.0466	7	0.0916	0.0678
		2	0.0780	0.0337	6	0.0639	0.0463
		3	0.0541	0.0174	10	0.0436	0.0456
Triangular	Uniform	1	0.0880	0.0632	6	0.0624	0.0535
		2	0.0336	0.0174	10	0.0091	0.0042
		3	0.0695	0.1028	9	0.0760	0.1929
	Normal	1	0.0288	0.0106	10	0.0038	0.0048
		2	0.0484	0.0424	9	0.0210	0.0315
		3	0.0251	0.0067	10	0.0033	0.0038
	Random	1	0.0843	0.0635	7	0.1050	0.1387
		2	0.0538	0.0294	9	0.0387	0.0486
		3	0.0438	0.0163	10	0.0201	0.0194
Bimodal	Uniform	1	0.1288	0.0259	0	0.3254	0.0146
		2	0.0358	0.0206	10	0.0192	0.0252
		3	0.0278	0.0172	10	0.0127	0.0040
	Normal	1	0.0509	0.0162	9	0.3417	0.0031
		2	0.0406	0.0135	10	0.0114	0.0094
		3	0.0374	0.0067	10	0.0018	0.0041
	Random	1	0.2432	0.0537	0	0.5813	0.2541
		2	0.0279	0.0078	10	0.0088	0.0060
		3	0.0318	0.0133	10	0.0070	0.0069

QGANの変分量子回路

対数正規分布を再現するための初期分布を一様分布/正規分布/ランダムを比較

20,000 samples
2000 epochs
AMSGRAD optimizer
learning late 10^{-4}

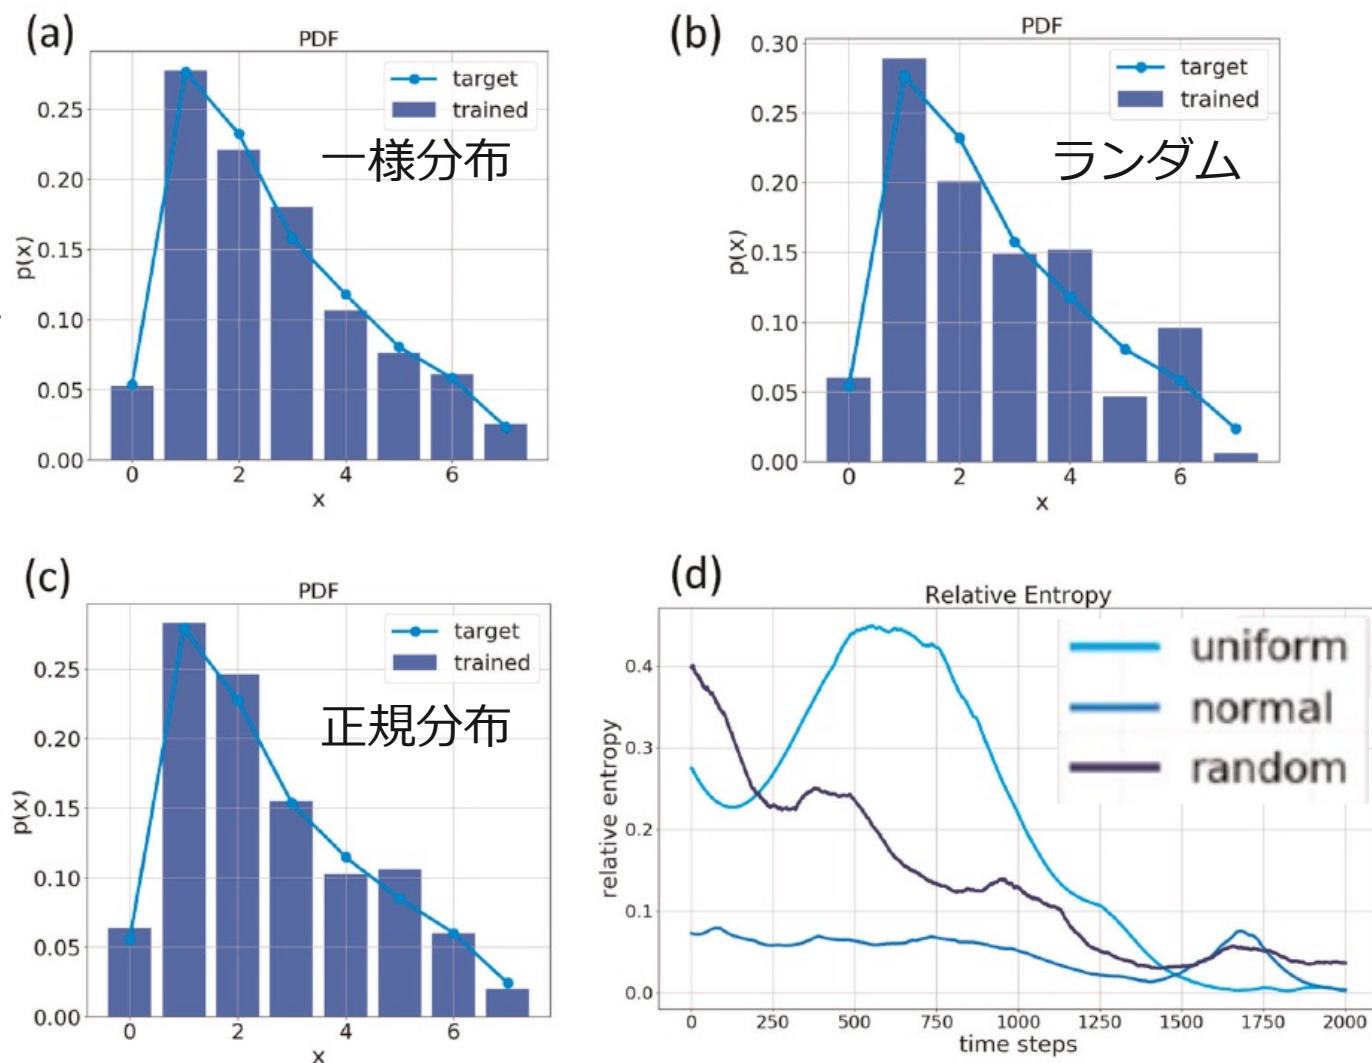
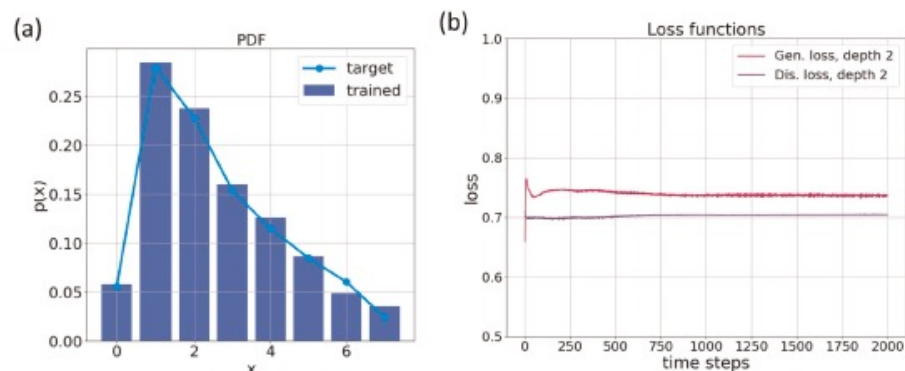


Fig. 4 Simulation training. The figure illustrates the PDFs corresponding to $|g_{\theta}\rangle$ trained on samples from a log-normal distribution using a uniformly (a), randomly (b), and normally (c) initialized quantum generator. Furthermore, the convergence of the relative entropy for the various initializations over 2000 training epochs is presented (d).

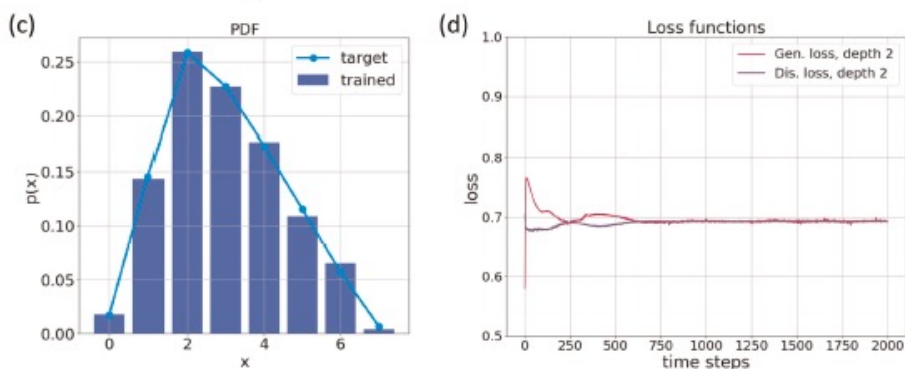
QGANの変分量子回路

正規分布を初期分布として対数正規分布/三角分布/双峰分布を再現

対数正規分布



三角分布



双峰分布

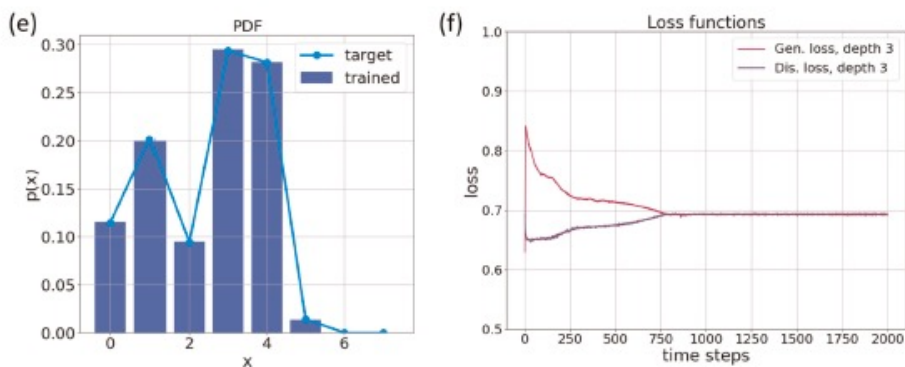


Fig. 3 Benchmarking results for qGAN training. Log-normal target distribution with normal initialization and a depth 2 generator (a, b), triangular target distribution with random initialization and a depth 2 generator (c, d), and bimodal target distribution with uniform initialization and a depth 3 generator (e, f). The presented probability density functions correspond to the trained $|g_\theta\rangle$ (a, c, e) and the loss function progress is illustrated for the generator as well as for the discriminator (b, d, f).

QGAN まとめ

- qGANを使うと価格の確率分布を再現でき、チュートリアルでは対数正規分布を再現
- qGANだと系統的に確率分布を作る場合に比べ少ないゲートで作成可能 $[O(2^n) \rightarrow O(\text{poly}(n))]$
- 量子部分のGeneratorと古典部分のDiscriminatorを競合させながら学習をする
競合させながら学習することで高度なダミーの確率分布を生成
- qGANのGeneratorの最適化関数 $L_G(\phi, \theta)$ と Discriminatorの最適化関数 $L_D(D_\phi, G_\theta)$ は以下で定義

$$L_G(\phi, \theta) = -\frac{1}{m} \sum_{l=1}^m [\log(D_\phi(G_\theta(z^l)))]$$

$$L_D(D_\phi, G_\theta) = \frac{1}{m} \sum_{l=1}^m [\log D_\phi(\mathbf{x}^l) + \log(1 - D_\phi(G_\theta(\mathbf{z}^l)))]$$

- 再現度合いは相互エントロピーで評価
- 初期分布の選択が重要で、正規分布の使用が推奨

Option Pricing計算フロー

(1) 確率分布 p_i を量子状態にエンコード

$$|\psi_1\rangle = \sum_{i=0}^{2^n-1} \sqrt{p_i} |i\rangle_n$$

本日のメイン
Quantum GAN
(Machine Learning)



(2) Payoff関数 f_i を量子状態にエンコード

$$|\psi_2\rangle = \sum_{i=0}^{2^n-1} \sqrt{1-f_i} \sqrt{p_i} |i\rangle_n |0\rangle + \sum_{i=0}^{2^n-1} \sqrt{f_i} \sqrt{p_i} |i\rangle_n |1\rangle$$

Controlled-Ry

(3) Payoffの期待値として振幅 $\sum_{i=0}^{2^n-1} (\sqrt{f_i} \sqrt{p_i})^2$ を計算

Amplitude Estimation
(詳しくは田中さんが後日発表)



Payoff関数のエンコード

$$\sum_{i=0}^{2^n-1} \sqrt{1-f(S_i)}\sqrt{p_i} |S_i\rangle |0\rangle + \sum_{i=0}^{2^n-1} \sqrt{f(S_i)}\sqrt{p_i} |S_i\rangle |1\rangle.$$

$f(S_i)$: シナリオ*i*でのスポット価格 S_i のPayoff

p_i : シナリオ*i*が起きる確率

$f(S_i)$ をどうエンコードするか?

まずは線型関数だけ考えればよい $f(i) = f_1 i + f_0$
 i.e. $|i\rangle_3 = |i_2 i_1 i_0\rangle, i = 4i_2 + 2i_1 + i_0 \in \{0, \dots, 7\}$
 $f(i) = 4f_1 i_2 + 2f_1 i_1 + f_1 i_0 + f_0$
 operator is,
 $|i\rangle_n |0\rangle \rightarrow |i\rangle_n (\cos[f(i)] |0\rangle + \sin[f(i)] |1\rangle)$

(1) p_i のエンコード(qGANが実現)

$$|\psi_1\rangle = \sum_{i=0}^{2^n-1} \sqrt{p_i} |i\rangle_n |0\rangle$$

(2) $f(S_i)$ のエンコード(Ryゲートを使用)

$$|\psi_2\rangle = \sum_{i=0}^{2^n-1} \sqrt{p_i} |i\rangle_n (\cos[f(i)] |0\rangle + \sin[f(i)] |1\rangle)$$

(3) 定数*c*を使って*f* を \tilde{f} でスケール化

$$|\psi_3\rangle = \sum_{i=0}^{2^n-1} \sqrt{p_i} |i\rangle_n \left(\cos \left[c\tilde{f}(i) + \frac{\pi}{4} \right] |0\rangle + \sin \left[c\tilde{f}(i) + \frac{\pi}{4} \right] |1\rangle \right) \quad \text{where } \tilde{f}(i) = 2 \frac{f(i) - f_{\min}}{f_{\max} - f_{\min}} - 1$$




Figure 2: Quantum circuit that creates the state in Eq. (9). Here, the independent variable $i = 4i_2 + 2i_1 + i_0 \in \{0, \dots, 7\}$ is encoded by three qubits in the state $|i\rangle_3 = |i_2 i_1 i_0\rangle$ with $i_k \in \{0, 1\}$. Therefore, the linear function $f(i) = f_1 i + f_0$ is given by $4f_1 i_2 + 2f_1 i_1 + f_1 i_0 + f_0$. After applying this circuit the quantum state is $|i\rangle_3 [\cos(f_1 i + f_0) |0\rangle + \sin(f_1 i + f_0) |1\rangle]$. The circuit on the right shows an abbreviated notation.

Payoff関数のエンコード

$$\sum_{i=0}^{2^n-1} \sqrt{1-f(S_i)}\sqrt{p_i} |S_i\rangle |0\rangle + \sum_{i=0}^{2^n-1} \sqrt{f(S_i)}\sqrt{p_i} |S_i\rangle |1\rangle.$$

$f(S_i)$: シナリオ*i*でのスポット価格*S_i* のPayoff
 p_i : シナリオ*i*が起きる確率

$f(S_i)$ をどうエンコードするか?

まずは線型関数だけ考えればよい $f(i) = f_1 i + f_0$
i.e. $|i\rangle_3 = |i_2 i_1 i_0\rangle, i = 4i_2 + 2i_1 + i_0 \in \{0, \dots, 7\}$
 $f(i) = 4f_1 i_2 + 2f_1 i_1 + f_1 i_0 + f_0$
operator is,
 $|i\rangle_n |0\rangle \rightarrow |i\rangle_n (\cos[f(i)] |0\rangle + \sin[f(i)] |1\rangle)$

小さい $\tilde{f}(i)$ に対して、補助量子ビットが $|1\rangle$ を観測する確率

$$|\langle 1 | \psi_3 \rangle|^2 = \sum_{i=0}^{2^n-1} p_i \sin^2 \left[c \tilde{f}(i) + \frac{\pi}{4} \right] \approx \sum_{i=0}^{2^n-1} p_i \left[c \tilde{f}(i) + \frac{\pi}{4} \right] \approx c \frac{2E[f(X)] - f_{\min}}{f_{\max} - f_{\min}} - c + \frac{1}{2}$$

c をうまく選べば $O(M^{-2/3})$ で収束
高次の近似で $O(M^{-1})$ も達成可能

m (s.t. $M = 2^m$) は量子ビット数





Figure 2: Quantum circuit that creates the state in Eq. (9). Here, the independent variable $i = 4i_2 + 2i_1 + i_0 \in \{0, \dots, 7\}$ is encoded by three qubits in the state $|i\rangle_3 = |i_2 i_1 i_0\rangle$ with $i_k \in \{0, 1\}$. Therefore, the linear function $f(i) = f_1 i + f_0$ is given by $4f_1 i_2 + 2f_1 i_1 + f_1 i_0 + f_0$. After applying this circuit the quantum state is $|i\rangle_3 [\cos(f_1 i + f_0) |0\rangle + \sin(f_1 i + f_0) |1\rangle]$. The circuit on the right shows an abbreviated notation.



Payoff関数のエンコード –Min/Maxのエンコード



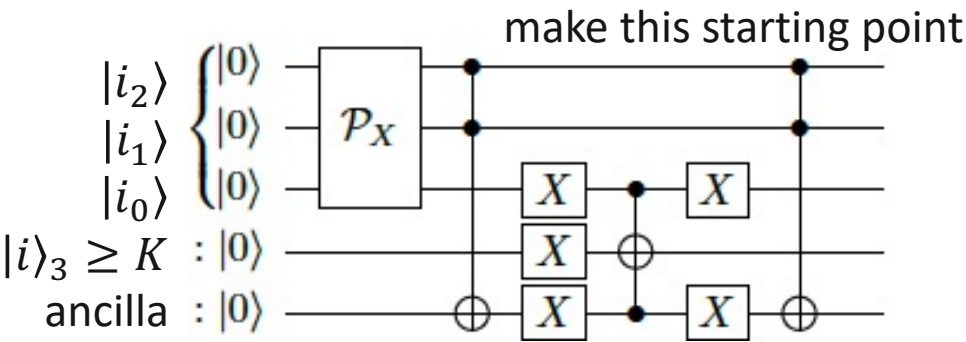
真偽値テーブルを使って0部分と線型部分を分離可能

$$|\psi\rangle_n |0\rangle \rightarrow |\phi_1\rangle = \sum_{i < K} \sqrt{p_i} |i\rangle_n |0\rangle + \sum_{i \geq K} \sqrt{p_i} |i\rangle_n |1\rangle.$$

Implement Following Truth Table

$$|i\rangle_3 = |i_2 i_1 i_0\rangle, K=1.9$$

Representing Price	i_2	i_1	i_0	$ i\rangle_3 \geq K$
1.500	0	0	0	False
1.643	0	0	1	False
1.786	0	1	0	False
1.929	0	1	1	True
2.071	1	0	0	True
2.214	1	0	1	True
2.357	1	1	0	True
2.500	1	1	1	True



Option Pricing計算フロー

(1) 確率分布 p_i を量子状態にエンコード

$$|\psi_1\rangle = \sum_{i=0}^{2^n-1} \sqrt{p_i} |i\rangle_n$$

本日のメイン
Quantum GAN
(Machine Learning)

(2) Payoff関数 f_i を量子状態にエンコード

$$|\psi_2\rangle = \sum_{i=0}^{2^n-1} \sqrt{1-f_i} \sqrt{p_i} |i\rangle_n |0\rangle + \sum_{i=0}^{2^n-1} \sqrt{f_i} \sqrt{p_i} |i\rangle_n |1\rangle$$

Controlled-Ry

(3) Payoffの期待値として振幅 $\sum_{i=0}^{2^n-1} (\sqrt{f_i} \sqrt{p_i})^2$ を計算



$$|\psi_2\rangle = \sum_{i=0}^{2^n-1} \sqrt{1-f_i} \sqrt{p_i} |i\rangle_n |0\rangle + \sum_{i=0}^{2^n-1} \sqrt{f_i} \sqrt{p_i} |i\rangle_n |1\rangle$$

Amplitude Estimation
(詳しくは田中さんが後日発表)

box link:


<https://ibm.ent.box.com/file/690593259852?s=bbbn6df18h7d1rcoiz4ut6pctau4nyhl>

|1>の部分を測定しても振幅が得られるが精度/効率が△



Option Pricingの精度

Amplitude Estimation(振幅推定)は量子ビットの数に応じて精度が向上



#	Single-qubit	CX	CCX	Depth
$m = 3$	2,091	2,056	90	3,927
$m = 5$	12,768	9,078	378	17,332
$m = 7$	52,275	37,132	1,530	70,916
$m = 9$	210,144	149,290	6,138	285,204

Table 2: Single-qubit, CNOT, Toffoli gate counts and overall circuit depth required for the full amplitude estimation circuits for each instance in Fig. 8, as a function of the number of sampling qubits m . These figures assume all-to-all connectivity across qubits.

qGAN部分の使用ゲート数は削減されたが、Payoff関数のエンコード、振幅推定部分の部分で必要ゲート数が指数的な気がする。。。→改善の余地あり!?

- qGANを使って価格の確率分布を量子状態としてエンコード
- Payoff関数をCos関数の線型近似&ロジック回路でエンコード
- 欲しい部分の振幅をAmplitude Estimationで計算